

DeepSolo-guided Hangul OCR

Apple Vision OCR의 한국어 읽기순서 보정과 HangulGuidedOCR 라이브러리

가반 27팀 정민지

Final Research Report, 2026

Abstract


This study translates DeepSolo's ordered-points, text-boundary, and reading-order representation into a Korean OCR correction strategy on top of Apple Vision OCR. The official DeepSolo inference pipeline could not be fully reproduced on macOS arm64 because of CUDA and Detectron2 dependencies. Instead, this work reproduced the output representation as a proxy: each Apple Vision observation is converted into center-line ordered points, boundary points, and ordered text units. The resulting pipeline applies ROI cropping, rotation, contrast/upscale preprocessing, ordered-point-based reading-order correction, expected-vocabulary reconstruction, and fuzzy correction to raw Apple Vision OCR outputs. For decorative vertical titles that Vision fails to detect at all, the system adds a pre-OCR ordered spot proposal branch that crops and normalizes the title region before recognition.

The core hard Korean set was expanded from four real failure seeds to N=20 by adding sixteen controlled vertical sign/poster cases. On this set, raw CER was 0.839, while the pre+post pipeline reduced CER to 0.006. The full experiment was re-aggregated under four conditions: raw Vision, preprocessing only, postprocessing only, and preprocessing plus postprocessing. In the title-critical Canva/MiriCanvas subset (N=24), raw CER was 5.250, post-only CER was 5.250, and pre+post CER was 0.080, showing that missing decorative titles require an ordered spot proposal before OCR. The single public-safe 'Gwangbokjeol' missing-title probe is included in the CER aggregate and is also reported by target recall. Its raw/post-only recall was 0.000/0.000, while pre-only/pre+post recall was 1.000/1.000. Over the Main GT set (N=784), raw CER was 1.209, pre-only CER was 0.067, post-only CER was 1.096, and pre+post CER was 0.018.

Keywords: DeepSolo, text spotting, Apple Vision OCR, Korean OCR, vertical text, reading order, HangulGuidedOCR

Overall System Overview

DeepSolo baseline reproduction → representation proxy → Apple Vision OCR guided experiment → final analysis



Key Message

DeepSolo ordered-points/boundary representation was reproduced as a proxy and adapted to HangulGuidedOCR(auto); the library preserves raw Vision order for ordinary horizontal posters and applies reordering only for vertical, multi-column, or dispersed Korean layouts.

Figure 1. 전체 연구 흐름: DeepSolo 재현, proxy 표현, Vision OCR 실험, 평가와 결론.




Figure 2. DeepSolo 표현을 Apple Vision OCR 보장 구조로 변환한 시스템 개요.

1. Introduction

모바일 앱에서 OCR 기능은 카메라 입력을 텍스트로 변환하는 핵심 기능이지만, 한국어 포스터·간판·안내문은 일반 문서 OCR보다 훨씬 복잡하다. 지하철 역명 판처럼 세로로 적힌 역 이름은 방향과 의미 단위 읽기 순서가 중요하고, 포스터 형 분산 타이포그래피는 단어가 일반적인 줄 구조를 따르지 않는다. Apple Vision OCR은 통제된 가로 텍스트에는 강하지만, 이러한 레이아웃에서는 observation이 검출되어도 사람이 기대하는 문자열 순서로 조립되지 않을 수 있다.

본 프로젝트의 목적은 DeepSolo 모델을 그대로 macOS에 이식하는 것이 아니라, DeepSolo가 제한한 text instance 표현, 즉 ordered points와 text boundary 관점을 Apple Vision OCR의 입력 보정과 출력 후처리로 옮기는 것이다. 따라서 실험은 표본 수 자체보다 한국어 OCR이 실제로 실패하는 지점을 해석하고, 어떤 layout prior가 필요한지를 찾는 데 집중한다.

연구 질문은 세 가지이다. 첫째, DeepSolo official baseline은 현재 Mac 환경에서 어디까지 재현 가능한가. 둘째, DeepSolo 표현을 proxy로 재현하면 Apple Vision OCR의 한국어 reading-order 실패를 설명하고 보정할 수 있는가. 셋째, 이 보정 전략을 실제 개발자가 사용할 수 있는 Swift/Xcode 라이브러리 API로 일반화할 수 있는가.

2. Related Work

Scene text spotting 연구는 detection과 recognition을 분리한 Rol 기반 구조, segmentation 기반 구조, 그리고 Transformer 기반 end-to-end 구조로 발전해 왔다. CRNN은 CNN-RNN-CTC 계열의 scene text recognizer를 대표하고, ASTER는 rectification을 결합한 recognition baseline으로 자주 비교된다. TextBoxes, EAST, CRAFT, DBNet 계열은 장면 텍스트 검출을 안정화했고, ABCNet과 TESTR는 곡선형 텍스트와 end-to-end spotting을 다루었다. DeepSolo는 이 흐름에서 text instance를 explicit points와 boundary-aware representation으로 표현해, 단순 사각형 bbox가 잃어버리는 중심선·경계·순서 정보를 모델 내부 표현으로 끌어올린다.

OCR 엔진 측면에서 Apple Vision OCR, Tesseract, EasyOCR, Naver CLOVA OCR 같은 시스템은 문서형·가로형 텍스트에는 강하지만, 한국어 포스터나 간판의 세로쓰기·다열·분산 타이포그래피에서는 사람이 기대하는 읽기순서를 항상 보장하지 않는다. 기존 OCR API는 인식 문자열과 위치 observation을 반환하지만, 한국어 앱 개발자가 역명판, 안내문, 메뉴판처럼 domain vocabulary와

layout prior를 알고 있을 때 이를 DeepSolo식 ordered point representation으로 변환해 체계적으로 적용하는 Swift 라이브러리 층은 상대적으로 부족하다.

Reading-order estimation and Korean OCR are also relevant.

LayoutReader shows that document reading order can be modeled as a layout-aware ordering problem rather than as a simple left-to-right text concatenation task. Korean OCR work such as Hangul character decomposition addresses the combinatorial structure and class imbalance of Hangul syllables, while KORIE-style Korean receipt benchmarks highlight that Korean OCR evaluation must consider domain-specific layout and transcription rules. These studies motivate this report's focus on Korean layout priors: subway station labels, vertical notices, poster titles, and dispersed typography require different ordering assumptions even when the underlying OCR engine is unchanged.

본 연구는 새 OCR recognizer를 학습하는 대신, DeepSolo의 ordered-points/boundary 관점을 Apple Vision OCR의 전처리·후처리 구조로 변환한다. 따라서 기여점은 DeepSolo 성능을 직접 재현하는 것이 아니라, text spotting representation을 한국어 reading-order correction과 Xcode용 HangulGuidedOCR API 설계로 번역하는 데 있다.

3. DeepSolo Reproduction and Proxy

DeepSolo는 Transformer encoder-decoder 구조에서 text instance를 명시적인 point query와 point prior로 표현한다. 논문에서 한 이미지 I 의 출력은 $\{(P_i, y_i, s_i)\}$ 꼴로 정리되며, P_i 는 텍스트 중심선/경계와 연결되는 points, y_i 는 인식 문자열, s_i 는 confidence score로 해석할 수 있다. 기본 구조는 Top-K Bezier center curve proposal을 만들고, 각 curve에서 $N=25$ 개의 ordered point를 uniform sampling한 뒤, content query와 positional query를 합쳐 decoder에 넣는 방식이다. decoder는 text/background score, character class, center points, boundary points를 예측하고, 최종 문자열은 CTC decoding으로 정리된다.

공식 GitHub 코드는 Detectron2, CUDA, 특정 PyTorch/CUDA 조합에 크게 의존한다. 본 실험 환경은 macOS arm64 기반이므로 CUDA inference가 직접 실행되지 않았고, Docker/UTM 재현도 dependency resolution과 GPU 가속 부재로 실제 모델 추론까지 도달하지 못했다. 따라서 재현 기록은 실패 로그를 남기는 official inference reproduction과, 논문 출력 표현을 구현 가능한 proxy로 재현하는 representation reproduction으로 분리했다.

Proxy 재현에서는 Apple Vision이 반환한 위치 observation을 25개 center-line ordered point와 boundary point polygon으로 변환했다. 이 값은 DeepSolo의 learned point query가 아니므로 모델 성능 재현이라고 주장할 수 없다. 대신 DeepSolo식 representation이 왜 Apple Vision OCR 보정에 유용한지 설명하는 구조적 재현이다. 즉 Vision observation을 텍스트 단위의 위치·순서·경계 표현으로 바꾸고, 이 표현을 reading-order 정렬, ROI 제한, 중복 point suppression, CTC-like 반복 문자 collapse에 사용했다. 또한 OCR이 텍스트를 아예 검출하지 못하는 경우에는 Apple Vision observation 이후가 아니라 OCR 전에 ordered spot proposal을 지정하는 branch를 추가했다.

official reproduction: demo.py와 Docker runbook을 점검했으나 CUDA/Detectron2/macOS arm64 제약으로 중단되었다.

proxy reproduction: Vision observation을 25개 center-line ordered points, boundary points, label 시각화로 변환했다.

point decoding: 반복 point 예측은 `광광광복절` → 광복절`처럼 CTC-like collapse로 정리한다.

application: 이 proxy 표현을 ROI, reading order, expected vocabulary 보정과 HangulGuidedOCR API 요구사항으로 연결했다.

4. Method

전체 파이프라인은 입력 이미지, Vision OCR variant, DeepSolo-style representation proxy, Apple Vision OCR 결과, metrics 단계로 구성된다. 입력 단계에서는 전체 이미지 OCR뿐 아니라 ROI crop, rotate, contrast, upscale2를 적용했다. Representation proxy 단계에서는 OCR observation을 ordered points와 boundary points로 변환하고, layout strategy에 따라 텍스트 component를 재정렬한다.

Apple Vision observation $o_i=(B_i, y_i, s_i)$ 가 주어지면, B_i 의 네 꼭짓점을 $b_{tl}, b_{tr}, b_{br}, b_{bl}$ 로 둔다. 가로 또는 회전 보정된 text strip에서는 중심선 양 끝을 $c_0=(b_{tl}+b_{bl})/2$, $c_1=(b_{tr}+b_{br})/2$ 로 정의하고, $N=25$ 개의 ordered center-line point를 $p_k=(1-t_k)c_0+t_k c_1$, $t_k=k/(N-1)$, $k=0,...,N-1$ 로 샘플링한다. 이때 $P_i=\{p_0,...,p_{24}\}$, y_i 는 top OCR candidate, s_i 는 confidence이며, boundary proxy는 $B_i=\{b_{tl},b_{tr},b_{br},b_{bl}\}$ 로 보존한다. 세로 열이나 회전 ROI는 같은 식을 보정된 좌표계에서 적용한 뒤 원본 좌표계로 되돌린다.

Algorithm	Procedure
bbox→points	Input observation $o=(B,y,s)$; order B as tl,tr,br,bl; set $c_0=(tl+bl)/2$ and $c_1=(tr+br)/2$.
sampling	For $k=0..24$, set $t=k/24$ and $p_k=(1-t)c_0+t c_1$; return $P=\{p_k\}$, boundary B, text y, score s.
ordering	Group point proxies by candidate layout; sort by x/y center according to horizontal, vertical $L\rightarrow R/R\rightarrow L$, or top-to-bottom strategy.
decoding	Suppress overlapping proposals, then collapse repeated adjacent labels so 광광광복절 becomes 광복절.

Algorithm 1. Vision bbox를 DeepSolo-style ordered-point proxy로 변환하는 절차.

Algorithm	Procedure
proposal	Input image I, ROI/layout prior R, expected terms E, orientation hint θ .
normalize	For each ROI $r\in R$, crop $I_r=crop(I,r)$, rotate or unwrap by θ , then apply upscale/contrast when needed.
pre-OCR	Run Apple Vision on I_r before full-image ordering; convert detected boxes to P_i with Algorithm 1.
gate	If target recall is low or the main title is missing, keep the proposal; otherwise preserve raw Vision order.
merge	Merge proposal text with raw observations using expectedOrder/fuzzy vocabulary only when domain terms are supplied.

Algorithm 2. OCR 전 ordered spot proposal 생성과 auto gate 흐름.

Reading strategy는 horizontal-lines, vertical-columns-left-to-right, vertical-columns-right-to-left, top-to-bottom으로 나뉜다. HangulGuidedOCR는 항상 OCR wrapper로 호출되지만, 내부 auto strategy가 layout을 판정한다. 지하철 세로 역명판은 90도 회전 후 영어 병기 위→아래 순서와 같은 역명 순서로 '동대문역사 문화공원'을 조립해야 하며, user_typography_wall은 위에서 아래로 읽어 '예쁜 그림을 그리고 싶다'가 되어야 한다. 일반 가로 포스터는 HangulGuidedOCR 내부에서 raw Vision 순서를 보존하고 재정렬을 생략한다.

Auto strategy의 판정 기준은 관찰된 OCR observation에서 샘플링한 ordered point proxy의 중심선 형태와 분포에 기반한다. observation이 1개 이하이면 raw order를 유지한다. height > 2.0 × width인 tall point sequence가 2개 이상이고 x 방향 center spread가 0.10을 넘으면 vertical-columns 계열 후보로 본다. row grouping 결과가 expected term count 이상이고 y spread가 0.18보다 크며 y spread > 0.75 × x spread이면 top-to-bottom rows로 판정한다. 이 조건을 만족하지 않는 대부분의 일반 포스터·카드뉴스는 rawVisionOrder로 남겨, 무조건 point sort가 문단 순서를 망치는 일을 피한다. Expected vocabulary 기반 보정은 OCR이 검출한 부분 문자열이 목표 어휘와 가까운 경우 fuzzy matching으로 교정하는 방식이다. 이 보정은 임의의 문장을 만들어내기 위한 것이 아니라 앱 개발자가 이미 알고 있는 domain vocabulary, 예를 들어 지하철 역명, 메뉴명, 안내문 키워드가 있을 때만 제한적으로 사용한다.

Case	Auto action	Expected output
Horizontal poster	Keep raw order	raw 수준 CER 유지
Subway station	Rotate + expectedOrder	동대문역사 문화공원
Top-to-bottom	Row sort + vocab	예쁜 그림을 그리고 싶다
Known terms	Fuzzy correction	앱 도메인 어휘 복구

Table 1. HangulGuidedOCR(auto)의 layout별 내부 판단 규칙.

5. Experimental Setup

실험은 여섯 계층으로 나누었다. 첫째, Core hard Korean set 20개는 기존 실제 실패 사례 4개와 새 세로쓰기/간판형 controlled hard expansion 16개로 구성했다. 새 16개는 독립 촬영 real-photo가 아니라, 로컬 포스터·간판·지하철 배경 위에 정답 전사가 알려진 한국어 세로쓰기/간판형 문구를 배치한 controlled failure probe이다. 둘째, targeted Korean poster synthetic 600장은 `광복절` 류 큰 세로 제목, 붓글씨형 세로 포스터, 지하철 세로 역명판, 분산 타이포그래피 등 layout 변인을 통제한다. 셋째, Canva/MiriCanvas 로컬 템플릿 124장은 사용자가 직접 전사한 실제 디자인 템플릿 기반 샘플이다. 넷째, 이 로컬 템플릿 중 제목 누락/왜곡이 큰 title-critical subset 24개를 별도로 분리해 전체 포스터 CER에서 희석되는 큰 제목 실패를 측정했다. 다섯째, 사용자가 GT를 채운 공개 한글 간판 15개를 보조 실제 간판 평가로 포함했다. 여섯째, 저작권 문제가 없는 public-safe `광복절` missing-title probe 1장을 포함해 OCR 전 ordered spot proposal의 필요성을 별도 확인했다.

정량 지표는 CER(Character Error Rate), WER(Word Error Rate), term recall, processing time이다. CER는 $ED(\text{norm}(\hat{y}), \text{norm}(y))/|y|$ 로 계산했고, 한글·영문·숫자 혼합 샘플은 NFC 정규화와 공백 정리를 적용했다. 공개 한글 간판은 사용자가 채운 수동 GT가 있는 행만 포함했고, 0012와 0013처럼 동일 이미지 해시가 반복되는 경우에는 중복을 제거했다.

CER는 0과 1 사이로 제한하지 않았다. 편집거리 기반 CER에서는 GT가 짧은 제목인데 OCR이 긴 주변 문구나 숫자를 함께 출력하면 삽입 오류가 GT 문자 수보다 많아질 수 있으므로 CER가 1을 넘는다. 따라서 title-critical과 stylized title 결과의 큰 CER 값은 제목 누락과 주변 텍스트 과검출이 동시에 일어난 실패 강도를 나타낸다.

Set	N	GT	Role
Core hard	20	Y	4 real seed + 16 hard expansion
Target synth	600	Y	세로 제목/역명/다열 통제
Manual templates	124	Y	사용자 전사 포스터
Title-critical	24	Y	큰 제목 누락형 로컬 probe
Public signs	15	Y	수동 GT 공개 한글 간판
Stylized title	1	Y	public-safe 제목 누락 probe

Table 2. 본실험 및 보조 probe 구성.

6. Results

Set	N	Raw	Pre	Post	Full
Hard expansion	16	0.947	0	0.938	0
Real seed	4	0.408	0.0278	0.408	0.0278
Title-critical	24	5.25	1.68	5.25	0.0799
Manual templ.	124	0.0602	0.0602	0.191	0.0602
Public signs	15	0.283	0.283	0.284	0.284
Stylized title	1	14	0.333	14	0
Target synth	600	1.3	0	1.13	0
Main GT weighted	784	1.21	0.0669	1.1	0.0175

Table 3. raw Vision, 전처리만, 후처리만, 전처리+후처리 조건의 CER 비교. 단일 missing-title probe도 main GT 평균에 포함하고, target recall은 Table 4에서 별도 해석했다.

주요 aggregate는 평균과 표준편차를 함께 해석해야 한다. Main GT 전체에서는 raw CER 1.209 ± 1.574 , pre-only CER 0.067 ± 0.374 , post-only CER 1.096 ± 1.611 , pre+post CER 0.018 ± 0.078 였다. 표준편차가 큰 이유는 일반 가로형 템플릿과 제목 누락형 포스터처럼 실패 강도가 서로 다른 하위 집합을 함께 포함했기 때문이다. 따라서 aggregate CER 단일 수치는 전체 경향을 요약하는 weighted summary로 해석해야 하며, 실제 성능 판단은 하위 세트별 결과와 함께 보아야 한다.

Case	Raw	Pre	Post	Full
광복절	0.000	1.000	0.000	1.000

Table 4. OCR 전 ordered spot proposal이 필요한 missing-title probe의 target recall.

Mode	CER	WER	Decision
Raw Vision	0.060	0.087	baseline
Forced proxy	0.191	0.238	order harmed
HG OCR(auto)	0.060	0.087	keep raw

Table 5. 일반 가로 포스터에서 forced proxy reorder가 왜 위험한지 확인한 auto-gate ablation.




Figure 3. main GT 784개에서 Raw, Pre-only, Post-only, Pre+Post 조건별 CER 비교.




Figure 4. GT가 있는 집합에서 raw Vision 대비 HangulGuidedOCR(auto) CER 변화.




Figure 5. Canva/MiriCanvas 전사 세트에서 forced proxy reorder와 auto 판단 비교.




Figure 6. 장식적 세로 제목에서 raw OCR 누락을 pre-OCR ordered spot proposal로 복구한 과정.

Core hard Korean set은 기존 실제 실패 사례 4개와 controlled hard poster/sign expansion 16개를 합친 N=20 세트이다. 기존 실제 사례에서는 지하철 역명판의 raw 출력이 '동대문역사'에 머무르거나, 분산 타이포그래피가 '힘 싣 다 왜'처럼 잘못 조립되었다. 지하철 사례의 최종 정답 순서는 영어 병기 위아래 순서와 같은 '동대문역사 문화공원'으로 정정했다. 새 16개 세로쓰기/간판형 샘플에서는 raw Vision이 세로 문구를 대부분 검출하지 못해 평균 raw CER 0.947±0.212를 기록했고, ordered-point proxy로 만든 guided/unwrapped 입력은 CER 0.000±0.000을 기록했다. 다만 이 16개는 독립 촬영 real-photo가 아니라 controlled hard expansion이므로, 실제 사진 benchmark가 아니라 실패 조건 보강으로 해석한다.

반면 사람이 전사한 Canva/MiriCanvas 124장은 대부분 일반 가로형 포스터·카드뉴스였고, Apple Vision raw가 이미 높은 성능을 보였다. 이 집합에서 ordered-point proxy reorder를 무조건 적용하면 자연스러운 문단 순서를 깨뜨려 평균 CER가 0.060에서 0.191로 악화되었다. 이 forced proxy 결과는 최종 방식이 아니라 auto gate가 필요한 이유를 보이는 ablation이다. HangulGuidedOCR(auto)는 이 샘플들을 horizontal layout으로 판단해 재정렬을 생략하므로 CER 0.060을 유지했다. 따라서 최종 비교 대상은 'raw Vision vs forced proxy'가 아니라 'raw Vision vs 항상 호출되는 HangulGuidedOCR(auto)'이다.

Canva/MiriCanvas에서 큰 제목이 빠지거나 왜곡되는 title-critical subset 24개는 전체 포스터 CER로 평가하면 본문 길이에 의해 실패가 희석된다. 그래서 제목부만 target으로 둔 별도 평가를 추가했다. 이 subset에서 raw CER는 5.250, post-only CER는 5.250로 거의 복구되지 않았지만, pre+post CER는 0.080로 낮아졌다. 즉 '광복절' 류 제목 누락은 OCR 후 정렬보다 OCR 전 ordered spot/proposal이 핵심이다.

새 targeted Korean poster synthetic은 600장으로 재생성했으며, 그중 stylized vertical title, vertical brush poster, vertical station board, vertical notice poster처럼 세로 제목/역명판 유형이 다수를 차지한다. 이 세트에서 raw CER는 1.299, pre+post CER는 0.000였다. 또한 사용자가 수동 GT를 채운 공개 한글 간판 15개는 중복 이미지를 제거해 포함했으며, 이 세트는 별도 ROI/proposal annotation이 없어 raw와 pre/post의 차이가 작게 나타났다.

Table 3의 Main GT weighted는 각 세트 평균의 단순 평균이 아니라 샘플 수로 가중한 평균이다. 계산에는 Real seed, Hard expansion, Target synthetic, Manual templates, Title-critical templates, Public Korean signs, 단일 public-safe '광복절' missing-title probe가 포함된다. 이 probe는 제목 검출 실패의 성격을 분명히 보이기 위해 Table 4에서 target recall도 함께 보고했다.


Sample	Raw	Auto	Guided text
subway_dongdaemu	0.444	0.000	동대문역사 문화공원
user_typography_	0.900	0.000	예쁜 그림을 그리고 싶다
real_busy_street	0.091	0.091	장국전문 비빔밥 아침식사 생태찌개
user_movie_poste	0.263	0.000	악하게 재미있다 올해 최고 의 영화

Table 6. 핵심 실패 실패 샘플의 대표 복구 결과.

Subway vertical sign recovery

세로 역명판 ROI를 옆으로 돌린 뒤, 검출된 두 한글 열을 한국어 역명판 읽기 순서로 재배열한다.


(a) Vertical Korean ROI



(b) Rotate 90° + ordered points



(c) Guided reading order



(d) Result

Recovered output

raw: 2 4 & Culture Park 동대문역사 문화공원

auto: 동대문역사 문화공원

target recall: 0.000 → 1.000

Figure 7. 지하철 세로 역명판 변환 과정.

Typography poster recovery

분산된 한글 component를 위에서 아래로 정렬한 strip으로 만들고 기대 문장 보정으로 복원한다.

(a) Original poster



(b) Ordered points overlay



(c) Component strip + correction

ordered component strip

예쁜 그림을 그리고 싶다

raw strip OCR: 예는 그림을 그리고 싶다

auto: 예쁜 그림을 그리고 싶다

(d) Result

Recovered output

raw full image CER: 0.900

component strip CER: 0.100

auto corrected CER: 0.000

Figure 8. 분산 타이포그래피 포스터 변환 과정.

7. Discussion

이번 실험의 핵심은 HangulGuidedOCR가 항상 사용되는 상황에서 내부 자동 판단이 필요하다는 점이다. 세로쓰기와 분산 타이포그래피는 OCR 엔진이 글자를 일부 검출하더라도 문자열 조립 순서가 틀어지므로 ordered point sequence와 boundary prior가 효과적이다. 반대로 일반 가로 포스터는 Vision이 이미 문단 순서를 잘 보존하므로 HangulGuidedOCR(auto)가 point proxy reorder를 적용하지 않아야 한다.

이 결과는 HangulGuidedOCR 라이브러리 설계에 직접 반영된다. 라이브러리는 raw Vision wrapper 위에 image transform, reading strategy, expectedOrder correction을 올리고, auto mode에서는 layout evidence를 기준으로 재정렬 적용 여부를 판단한다. 개발자가 지하철 역명판, 세로 안내문, 분산 타이포그래피처럼 layout prior를 알고 있으면 strategy를 명시할 수 있고, 명시하지 않아도 일반 가로형에서는 raw order를 보존하는 방향으로 동작한다.

따라서 본 연구의 성공은 '무조건 재정렬을 적용한다'가 아니라 'HangulGuidedOCR를 항상 채택했을 때 내부 auto strategy가 개선이 필요한 경우와 raw order를 보존해야 하는 경우를 구분한다'는 데 있다. 이는 실제 앱 개발에서 매우 중요하다. 라이브러리는 어려운 세로/다열 샘플을 개선하면서도, 이미 잘 되는 일반 포스터를 망치지 않아야 제품 기능으로 사용할 수 있기 때문이다.

8. Library-oriented System Implementation

연구 결과는 별도 SwiftPM repo인 HangulGuidedOCR로 확장된다. 이 섹션은 사용법을 나열하기보다, 실험에서 도출된 설계 원칙을 정리한다. 첫째, 라이브러

리는 Apple Vision OCR을 대체하지 않고 wrapper로 감싼다. 둘째, Vision observation을 그대로 bbox 정렬에 쓰지 않고 HangulPointProxyBuilder를 통해 `(P\_i, y\_i, s\_i)` 형태의 ordered point proxy로 바꾼다. 셋째, 모든 입력에 보정을 강제하지 않고, auto mode에서 layout evidence가 충분할 때만 reading-order 보정을 적용한다. 넷째, 개발자가 지하철 역명, 메뉴명, 안내문 키워드처럼 domain vocabulary를 알고 있을 때 expectedOrder/fuzzy correction을 명시적으로 넘길 수 있게 한다.

Vision wrapper: VNRecognizeTextRequest 기반 ko-KR OCR 실행, text observation과 confidence 반환.

Spotting proposal: OCR 전 `HangulSpottingProposal`로 ROI boundary, 25 ordered points, score, rotation hint를 전달.

Point proxy: 각 observation을 25개 center-line ordered points와 4개 boundary points로 변환.

Point decoding: 겹치는 proposal은 overlap suppression으로 줄이고, 반복 point 문자는 CTC-like collapse로 정리.

Image transform: ROI crop, rotate, upscale, contrast preprocessing.

Reading strategy: horizontal, vertical L→R, vertical R→L, top-to-bottom.

Correction: expectedOrder, target terms, fuzzy vocabulary correction.

Tests: subway vertical station board와 user typography wall recovery.

성능 오버헤드는 선택한 전처리와 Vision OCR 실행 횟수에 따라 달라진다. 일반 가로형에서는 raw order를 유지하므로 추가 비용은 observation 분석과 문자 열 재조립 수준에 머문다. 세로쓰기/간판형에서는 ROI crop, rotate, unwrapped strip OCR이 들어가므로 단일 raw OCR보다 시간이 늘 수 있지만, Core hard set에서 보듯 실패 문구를 검출 가능한 입력으로 바꾸는 효과가 더 중요하다. 따라서 라이브러리는 정확도가 필요한 domain-specific 입력에서 strategy를 명시하고, 일반 포스터에서는 auto가 raw order를 보존하는 방향으로 설계했다.

라이브러리 repo와 연구 repo는 분리한다. 연구 repo는 실험 산출물, 논문형 보고서, DeepSolo 재현 기록을 보존하고, HangulGuidedOCR repo는 실제 앱 개발자가 import할 수 있는 product-facing package로 유지한다. 두 repo의 README는 같은 결론을 공유하되, 전자는 실험 근거를, 후자는 API 사용법을 중심으로 작성한다.

9. Limitations and Future Work

첫째, DeepSolo official inference는 CUDA Linux 환경에서 완전 재현하지 못했다. 따라서 본 보고서의 DeepSolo 결과는 모델 성능 재현이 아니라 representation proxy 재현이다. 둘째, Core hard set은 20개로 확장했지만 그중 새 16개는 독립 촬영 real-photo가 아니라 controlled hard poster/sign expansion이다. 이 세트는 실패 조건 보강에는 유용하지만, 한국어 실제 환경 전체를 대표하는 통계 표본으로 과장해서는 안 된다. 셋째, 로컬 Canva/MiriCanvas 템플릿은 전사와 평가에는 사용했지만 원본 이미지는 라이선스와 공개 범위 문제로 GitHub에 포함하지 않는다.

향후 작업은 실제 한국어 사진 50~200장을 지하철, 포스터, 간판, 안내문 유형 별로 균형 있게 수집하고, ROI와 reading-order annotation을 함께 작성하는 것이다. 또한 각 컴포넌트를 하나씩 제거하는 full ablation, bootstrap confidence interval, paired significance test를 추가해야 한다. 세로쓰기 자동 판별, 열 검출, 글자 단위 crop/unwarp, vocabulary 없이도 동작하는 layout classifier를 추가하면 라이브러리의 자동화 수준을 높일 수 있다.

10. Conclusion

본 연구는 DeepSolo의 ordered-points/boundary 표현을 Apple Vision OCR의 전처리·후처리 전략으로 변환하여, 한국어 세로쓰기·다열 안내문·분산 타이포그래피 이미지의 읽기순서 오류를 개선하는 방법을 제안했다. Core hard set, targeted synthetic, title-critical probe에서는 pre-OCR proposal과 ordered-point correction의 효과를 확인했고, 일반 가로형 포스터에서는 auto strategy가 raw order를 보존해 손상을 피했다. 따라서 DeepSolo는 단순 비교 baseline이 아니라 Apple Vision OCR 결과를 point, boundary, ordered text unit으로 다시 해석하게 만든 이론적 기반이며, 이 해석은 HangulGuidedOCR 라이브러리로 확장된다.

References

- [1] M. Ye et al., DeepSolo: Let Transformer Decoder with Explicit Points Solo for Text Spotting, CVPR, 2023.
- [2] B. Shi, X. Bai, and C. Yao, An End-to-End Trainable Neural Network for Image-based Sequence Recognition and Its Application to Scene Text Recognition, IEEE TPAMI, 2017.
- [3] B. Shi et al., ASTER: An Attentional Scene Text Recognizer with Flexible Rectification, IEEE TPAMI, 2019.
- [4] Y. Baek et al., What Is Wrong With Scene Text Recognition Model Comparisons? Dataset and Model Analysis, ICCV, 2019.
- [5] M. Liao et al., TextBoxes: A Fast Text Detector with a Single Deep Neural Network, AAAI, 2017.
- [6] X. Zhou et al., EAST: An Efficient and Accurate Scene Text Detector, CVPR, 2017.
- [7] Y. Baek et al., Character Region Awareness for Text Detection, CVPR Workshops, 2019.
- [8] M. Liao et al., Real-time Scene Text Detection with Differentiable Binarization, AAAI, 2020.
- [9] Y. Liu et al., ABCNet: Real-time Scene Text Spotting with Adaptive Bezier-Curve Network, CVPR, 2020.
- [10] W. Zhang et al., TESTR: Text Spotting Transformers, CVPR, 2022.
- [11] Z. Wang, Y. Xu, L. Cui, J. Shang, and F. Wei, LayoutReader: Pre-training of Text and Layout for Reading Order Detection, EMNLP, 2021.
- [12] M. S. Kasem, M. Mahmoud, M. F. Senussi, M. Abdalla, and H. S. Kang, KORIE: A Multi-Task Benchmark for Detection, OCR, and Information Extraction on Korean Retail Receipts, Mathematics, 14(1):187, 2026.
- [13] G. Kim, J. Son, K. Lee, and J. Min, Character Decomposition to Resolve Class Imbalance Problem in Hangul OCR, arXiv:2208.06079, 2022.
- [14] Apple Developer Documentation, Vision Framework, VNRecognizeTextRequest, accessed June 8, 2026.
- [15] R. Smith, An Overview of the Tesseract OCR Engine, ICDAR, 2007.
- [16] JaidedAI, EasyOCR GitHub repository, first public release around 2020, accessed June 8, 2026.
- [17] NAVER Cloud Platform, CLOVA OCR product documentation, accessed June 8, 2026.
- [18] Facebook Research, Detectron2 documentation and GitHub repository, accessed June 8, 2026.
- [19] ViTAE-Transformer, DeepSolo official GitHub repository, accessed June 8, 2026.
- [20] wjdalswl, HangulGuidedOCR: Apple Vision OCR 기반 한국어 읽기순서 보정 Swift Package, GitHub repository, accessed June 8, 2026.
<https://github.com/wjdalswl/HangulGuidedOCR>