

# DeepSolo-inspired Ordered-Point Hangul OCR: Apple Vision OCR의 한국어 읽기순서 보정과 HangulGuidedOCR 라이브러리

정민지

가반 27팀

**Abstract.** 본 연구는 한국어 포스터, 간판, 지하철 안내문처럼 글자가 세로로 배치되거나 분산된 실제 이미지에서 Apple Vision OCR의 읽기 순서 오류와 텍스트 누락 문제를 개선하는 것을 목표로 한다. DeepSolo의 ordered points와 boundary 기반 text spotting 표현을 분석하고, 공식 DeepSolo inference는 macOS arm64 및 CUDA/Detectron2 환경 제약으로 완전 재현하지 못했으나, bbox를 순서를 가진 25개 중심점과 boundary 정보로 변환하는 proxy 재현을 수행하였다. 이 표현에서 영감을 받아 Apple Vision OCR 결과를 보정하는 HangulGuidedOCR(auto)를 설계하고, raw Vision, preprocessing-only, postprocessing-only, pre+post auto 조건을 비교하였다. Main GT aggregate에서 raw Vision OCR의 CER은 1.209였으나 HangulGuidedOCR(auto)는 0.018로 감소하였다. 특히 세로 역명판, 분산 타이포그래피, 장식형 제목 누락 사례에서 읽기 순서 복구 효과가 뚜렷하였다.

**Keywords:** DeepSolo; Apple Vision OCR; Korean OCR; scene text spotting; reading order; Hangul-GuidedOCR




Fig. 1: DeepSolo의 ordered-point 표현에서 영감을 받아 Apple Vision OCR 보정 구조로 변환한 HangulGuidedOCR architecture.

## 1 Introduction

모바일 앱에서 OCR 기능은 카메라 입력을 텍스트로 변환하는 핵심 기능이지만, 한국어 포스터·간판·안내문은 일반 문서 OCR보다 복잡하다. 지하철 역명판처럼 세로로 적힌 역 이름은 방향과 의미 단위 읽기 순서가 중요하고, 포스터형 분산 타이포그래피는 단어가 일반적인 줄 구조를 따르지 않는다. Apple Vision OCR은 통제된 가로 텍스트에는 강하지만, 이러한 레이아웃에서는 observation이 검출되어도 사람이 기대하는 문자열 순서를 항상 보장하지 않는다.

본 프로젝트의 목적은 DeepSolo 모델을 그대로 macOS에 이식하는 것이 아니라, DeepSolo가 제안한 text instance 표현, 즉 ordered points와 text boundary 관점을 Apple Vision OCR의 입력 보정과 출력 후처리로 옮기는 것이다. 연구 질문은 세 가지이다. 첫째, DeepSolo official baseline은 현재 Mac 환경에서 어디까지 재현 가능한가. 둘째, DeepSolo 표현을 proxy로 재현하면 Apple Vision OCR의 한국어 reading-order 실패를 설명하고 보정할 수 있는가. 셋째, 이 보정 전략을 실제 개발자가 사용할 수 있는 Swift/Xcode 라이브러리 API로 일반화할 수 있는가. 따라서 본 연구의 기여는 Apple Vision OCR을 black-box baseline으로 두고, DeepSolo-inspired ordered-point proxy를 재현 가능한 보정 모듈로 구현하며, 그 효과를 CER/WER와 대표 실패 사례로 검증한 점이다.

## 2 Related Work

Scene text spotting 연구는 detection과 recognition을 분리한 RoI 기반 구조, segmentation 기반 구조, Transformer 기반 end-to-end 구조로 발전해 왔다. CRNN [7]과 ASTER [8]는 scene text recognition baseline으로 사용되며, TextBoxes [3], EAST [13], CRAFT [1], DB [4]는 text detection의 대표적 흐름을 이룬다. ABCNet [5], TESTR [12], DeepSolo [11]는 곡선 텍스트와 end-to-end spotting을 직접적으로 다룬다.

OCR 엔진 측면에서 Apple Vision OCR, Tesseract [9], EasyOCR [2], Naver CLOVA OCR [6] 같은 시스템은 문서형·가로형 텍스트에는 강하지만, 한국어 포스터나 간판의 세로쓰기·다열·분산 타이포그래피에서는 사람이 기대하는 읽기순서를 항상 보장하지 않는다. LayoutReader [10]는 reading order를 단순 left-to-right 연결이 아니라 layout-aware ordering 문제로 본다. 본 연구는 Apple Vision OCR의 내부 구조를 수정하거나 DeepSolo가 Apple Vision 안에 있다고 가정하지 않는다. Apple Vision OCR은 black-box baseline이고, DeepSolo는 end-to-end text spotting 연구에서 얻은 표현적 기준으로 사용된다.

## 3 Proposed Method

### 3.1 DeepSolo Reproduction and Proxy

DeepSolo는 Transformer encoder-decoder 구조에서 text instance를 명시적인 point query와 point prior로 표현한다. 논문에서 한 이미지  $I$ 의 출력은  $\{(P_i, y_i, s_i)\}$  꼴로 정리되며,  $P_i$ 는 텍스트 중심선/경계와 연결되는 points,  $y_i$ 는 인식 문자열,  $s_i$ 는 confidence score로 해석할 수 있다. 공식 GitHub 코드는 Detectron2, CUDA, 특정 PyTorch/CUDA 조합에 크게 의존한다. 본 실험 환경은 macOS arm64 기반이므로 CUDA inference가 직접 실행되지 않았고, Docker/UTM 재현도 dependency resolution과 GPU 가속 부재로 실제 모델 추론까지 도달하지 못했다.

따라서 재현은 두 단계로 정리하였다. 첫째, official reproduction은 demo.py와 Docker runbook을 점검하고 중단 지점을 기록하는 절차이다. 둘째, proxy reproduction은 Apple Vision이 반환한 위치 observation을 25개 center-line ordered points와 boundary polygon으로 변환하는 절차이다. 이 값은 DeepSolo의 learned point query가 아니므로 모델 성능 재현이라고 주장할 수 없다. 대신 DeepSolo-inspired representation이 왜 Apple Vision OCR 보정에 유용한지 설명하는 구조적 재현이다.

Table 1: DeepSolo 재현 범위와 proxy 변환 결과.

| Item                 | Result         | Interpretation                                                 |
|----------------------|----------------|----------------------------------------------------------------|
| Official inference   | Stopped        | CUDA/Detectron2/Linux dependency mismatch                      |
| Proxy representation | Completed      | Vision bbox $\rightarrow$ 25 ordered points + boundary polygon |
| Claim level          | Representation | Not a DeepSolo model-performance reproduction                  |

### 3.2 Overall Pipeline

전체 파이프라인은 입력 이미지  $\rightarrow$  ROI 탐지/크롭  $\rightarrow$  회전 보정  $\rightarrow$  대비/선명도/업스케일링  $\rightarrow$  Apple Vision OCR  $\rightarrow$  ordered-point 후처리  $\rightarrow$  CER/WER 평가 단계로 구성된다. 입력 단계에서는 전체 이미지 OCR뿐 아니라 ROI crop, rotate, contrast, upscale2를 적용했다. Representation proxy 단계에서는 OCR observation을 ordered points와 boundary로 바꾸고, auto strategy가 raw order를 유지할지 재정렬할지 판단한다.




Fig. 2: DeepSolo 재현, representation proxy, Apple Vision OCR 보정 실험, final analysis로 이어지는 전체 연구 흐름.

### 3.3 Ordered Point Conversion

Apple Vision observation  $o_i = (B_i, y_i, s_i)$ 가 주어지면,  $B_i$ 의 네 꼭짓점을  $b_{tl}, b_{tr}, b_{br}, b_{bl}$ 로 두고 중심선 양끝을  $c_0 = (b_{tl} + b_{bl})/2$ ,  $c_1 = (b_{tr} + b_{br})/2$ 로 정의한다.  $N = 25$ 개의 ordered center-line point는

$$p_k = (1 - t_k)c_0 + t_k c_1, \quad t_k = \frac{k}{N-1}, \quad k = 0, \dots, N-1 \quad (1)$$

로 샘플링한다. 이 point proxy는 horizontal-lines, vertical-columns-left-to-right, vertical-columns-right-to-left, top-to-bottom strategy 중 하나로 group/sort된다. 겹치는 proposal은 overlap suppression으로 줄이고, 반복 point 문자는 CTC-like collapse로 정리한다.

### 3.4 Pre-OCR Proposal and Auto Strategy

Pre-OCR spot proposal은 raw Vision이 큰 제목이나 세로 열을 놓치는 경우를 줄이기 위해 먼저 텍스트 후보 영역을 만든 뒤 Vision OCR을 실행하는 절차이다. 구현상 후보는 전체 이미지 OCR 결과, edge/contrast가 높은 ROI, 사용자 또는 앱 도메인이 제공하는 expected vocabulary hint를 결합해 만든다. 세로형 후보는 ROI를 90° 회전한 variant로 다시 OCR하고, 포스터 제목형 후보는 후보 영역 crop과 upscale variant를 추가한다. 이후 auto strategy가 raw, vertical L→R, vertical R→L, top-to-bottom 중 하나를 선택한다.

Table 2: HangulGuidedOCR(auto)의 layout 별 내부 판단 규칙.

| Case                     | Auto action            | Expected output |
|--------------------------|------------------------|-----------------|
| Horizontal poster        | Keep raw order         | raw 수준 CER 유지   |
| Subway station           | Rotate + expectedOrder | 동대문역사 문화공원      |
| Top-to-bottom typography | Row sort + vocab       | 예쁜 그림을 그리고 싶다   |
| Known domain terms       | Fuzzy correction       | 앱 도메인 어휘 복구     |

HangulGuidedOCR는 항상 OCR wrapper로 호출되지만, 내부 auto strategy가 layout을 판정한다. Observation이 1개 이하이면 raw order를 유지한다. Height가 width의 2배 이상인 tall point sequence가 2개 이상이고 x 방향 center spread가 0.10을 넘으면 vertical-columns 후보로 본다. 이 임계값은 학습된 최적값이 아니라 일반 가로 포스터를 해치지 않도록 둔 pilot default이다. Manual template에서 forced reorder CER는 0.191로 raw/auto CER 0.060보다 나빠져, auto gate가 필요한 근거가 된다.

### 3.5 Program Code

HangulGuidedOCR의 구현은 Vision OCR wrapper, point-proxy builder, reading-order resolver의 세 모듈로 나뉜다. Vision wrapper는 Apple Vision이 반환한 문자열, confidence, normalized bounding box를 수집하고, point-proxy builder는 각 box를 25개 ordered center-line point와 boundary polygon으로 변환한다. Reading-order resolver는 이 point sequence의 aspect ratio, column spread, row grouping evidence를 이용해 raw order를 유지할지 세로 열 또는 top-to-bottom 순서로 재배열할지 결정한다. Listing 1.1는 이 과정의 핵심 부분을 보인다. 일반 가로 문단에서는 `rawVisionOrder`가 반환되어 기존 Vision 결과가 보존되고, 세로/분산 레이아웃에서만 ordered-point 기반 재정렬이 적용된다.

Listing 1.1: Core Swift implementation excerpt from HangulGuidedOCR.

```
public static func orderedPoints(
    for observation: HangulTextObservation,
    sampleCount: Int = 25
) -> [HangulOrderedPoint] {
    let count = max(2, sampleCount), box = observation.boundingBox
    if box.height > box.width * 1.4 {
        return (0..

```

## 4 Experiments

### 4.1 Datasets and Ground Truth

실험은 여섯 계층으로 나누었다. Core hard Korean set 20개는 기존 실제 실패 사례 4개와 새 세로쓰기/간판형 controlled hard expansion 16개로 구성했다. Targeted Korean poster synthetic은 세로 제목/역명/다열 통제 샘플 600개, manual templates는 사용자가 전사한 Canva/MiriCanvas 포스터 124개, public Korean signs는 수동 GT가 있는 15개이다. 정량 지표는 CER(Character Error Rate), WER, term recall, processing time이며, CER는  $ED(norm(\hat{y}), norm(y))/|y|$ 로 계산했다. CER는 0과 1 사이로 제한하지 않았다. GT가 짧은 제목인데 OCR이 긴 주변 문구나 숫자를 함께 출력하면 삽입 오류가 GT 문자 수보다 많아질 수 있으므로 CER가 1을 넘는다.

Table 3: 본실험 및 보조 probe 구성.


| Set              | N   | Role                            |
|------------------|-----|---------------------------------|
| Core hard        | 20  | 4 real seed + 16 hard expansion |
| Target synth     | 600 | 세로 제목/역명/다열 통제                  |
| Manual templates | 124 | 사용자 전사 포스터                      |
| Title-critical   | 24  | 큰 제목 누락형 local probe            |
| Public signs     | 15  | 수동 GT 공개 한글 간판                  |
| Stylized title   | 1   | public-safe 제목 누락 probe         |

### 4.2 Evaluation Protocol and Results


실험은 macOS arm64에서 Apple Vision `VNRecognizeTextRequest`를 `.accurate, ko-KR` 설정으로 수행하였다. 동일 입력에 대해 raw, preprocessing-only, postprocessing-only, pre+post(auto)를 비교했다. 재현 자료는 <https://github.com/wjdalswl/textspotting-guided-vision-ocr>(실험 로그, 프로토콜, PDF)와 <https://github.com/wjdalswl/HangulGuidedOCR>(Swift package, 요약 결과, figure)로 분리했다.

Table 4: raw Vision, 전처리만, 후처리만, 전처리+후처리 조건의 CER 비교.

| Set              | N   | Raw    | Pre   | Post   | Full  |
|------------------|-----|--------|-------|--------|-------|
| Hard expansion   | 16  | 0.947  | 0.000 | 0.938  | 0.000 |
| Real seed        | 4   | 0.408  | 0.028 | 0.408  | 0.028 |
| Title-critical   | 24  | 5.250  | 1.680 | 5.250  | 0.080 |
| Manual templ.    | 124 | 0.060  | 0.060 | 0.191  | 0.060 |
| Public signs     | 15  | 0.283  | 0.283 | 0.284  | 0.284 |
| Stylized title   | 1   | 14.000 | 0.333 | 14.000 | 0.000 |
| Target synth     | 600 | 1.300  | 0.000 | 1.130  | 0.000 |
| Main GT weighted | 784 | 1.209  | 0.067 | 1.096  | 0.018 |



(a) Main GT CER by OCR variant.



(b) Raw Vision vs HangulGuidedOCR(auto).

Fig. 3: 정량 결과 그래프. Main GT 전체에서는 raw CER 1.209, pre-only CER 0.067, post-only CER 1.096, pre+post CER 0.018이었다.

Main GT weighted는 샘플 수 가중 평균이다. 하위 집합의 실패 강도가 달라 aggregate CER 단일 수치는 세부 subset과 함께 해석해야 한다. 정규 근사 95% CI는 Main GT raw  $1.209 \pm 0.110$ , full  $0.018 \pm 0.006$ 이고, Core hard raw  $0.835 \pm 0.147$ , auto  $0.005 \pm 0.009$ 이다. Public signs는  $N = 15$ 이므로 보조 관찰로만 해석한다.

Apple Vision OCR이 세로쓰기와 장식형 제목에서 약하다는 주장은 Table 3의 hard expansion, title-critical, stylized title 결과와 Fig. 4-6에 근거한다. 반대로 public signs와 manual templates는 본 방법이 모든 한글 OCR 오류를 해결하지 못함을 보여준다.




Fig. 4: 일반 가로 포스터에서 forced proxy reorder와 auto 판단 비교. 일반 가로형에서는 auto strategy가 raw order를 보존해야 한다.

## 5 Representative Cases and Discussion

### 5.1 Vertical Sign and Typography Cases

Core hard Korean set은 기존 실제 실패 사례 4개와 controlled hard poster/sign expansion 16개를 합친  $N=20$  세트이다. 기존 실제 사례에서는 지하철 역명판의 raw 출력이 “동대문역사”에 머무르거나, 분산 타이포그래피가 “형 싶 다 왜”처럼 잘못 조립되었다. 지하철 사례의 최종 정답 순서는 영어 병기 위→아래 순서와 같은 “동대문역사 문화공원”으로 정정했다.



(a) Subway vertical station sign recovery.

(b) Dispersed typography poster recovery.

Fig. 5: 대표 변환 사례. 원본/ROI, 회전 또는 strip 변환, ordered reading order, recovered output을 같은 흐름으로 배치하였다.

## 5.2 Title-Critical Spotting Failure

Canva/MiriCanvas에서 큰 제목이 빠지거나 왜곡되는 title-critical subset은 전체 포스터 CER로 평가하면 본문 길이에 의해 실패가 희석된다. 그래서 제목부만 target으로 둔 별도 평가를 추가했다. 이 subset에서 raw CER는 5.250, post-only CER는 5.250로 거의 복구되지 않았지만, pre+post CER는 0.080로 낮아졌다. 즉 ‘광복절’류 제목 누락은 OCR 후 정렬보다 OCR 전 ordered spot proposal이 더 중요하다.



Fig. 6: 장식적 세로 제목에서 raw OCR 누락을 pre-OCR ordered spot proposal로 복구한 과정.

## 5.3 Discussion

이번 실험의 핵심은 HangulGuidedOCR가 항상 사용되는 상황에서 내부 자동 판단이 필요하다는 점이다. 세로쓰기와 분산 타이포그래피는 OCR 엔진이 글자를 일부 검출하더라도 문자열 조립 순서가 틀어지므로 ordered point sequence와 boundary prior가 효과적이다. 반대로 일반 가로 포스터는 Vision이 이미 문단 순서를 잘 보존하므로 HangulGuidedOCR(auto)가 point proxy reorder를 적용하지 않아야 한다. 이는 실제 앱 개발에서 중요하다. 라이브러리는 어려운 세로/다열 샘플을 개선하면서도, 이미 잘 되는 일반 포스터를 망치지 않아야 제품 기능으로 사용할 수 있기 때문이다.

## 6 Limitations and Future Work

첫째, DeepSolo official inference는 CUDA Linux 환경에서 완전 재현하지 못했으므로 본 결과는 모델 성능 재현이 아니라 representation proxy 재현이다. 둘째, Core hard set의 새 16개는 독립 촬영 real-photo가 아니라 controlled hard expansion이다. 셋째, xSpread > 0.10 등은 pilot default이며, 체계적 threshold sweep은 향후 과제이다. 넷째, Canva/MiriCanvas 원본은 라이선스 문제로 GitHub에 포함하지 않는다.

## 7 Conclusion

본 연구는 DeepSolo-inspired ordered-points/boundary 표현을 Apple Vision OCR의 전처리·후처리 전략으로 변환하여, 한국어 세로쓰기·다열 안내문·분산 타이포그래피 이미지의 읽기순서 오류를 개선하는 방법을 제안했다. Core hard set, targeted synthetic, title-critical probe에서는 pre-OCR proposal과 ordered-point correction

의 효과를 확인했고, 일반 가로형 포스터에서는 auto strategy가 raw order를 보존해 손상을 피했다. 향후에는 실제 한국어 사진 50–200장을 유형별로 균형 있게 수집하고, threshold ablation, bootstrap confidence interval, paired significance test를 추가해야 한다.

## References

1. Baek, Y., Lee, B., Han, D., Yun, S., Lee, H.: Character region awareness for text detection. In: CVPR Workshops (2019)
2. JaideAI: Easyocr github repository (2020), accessed: 2026-06-08
3. Liao, M., Shi, B., Bai, X., Wang, X., Liu, W.: Textboxes: A fast text detector with a single deep neural network. In: AAAI Conference on Artificial Intelligence (2017)
4. Liao, M., Wan, Z., Yao, C., Chen, K., Bai, X.: Real-time scene text detection with differentiable binarization. In: AAAI Conference on Artificial Intelligence (2020)
5. Liu, Y., Chen, H., Shen, C., He, T., Jin, L., Wang, L.: Abcnet: Real-time scene text spotting with adaptive bezier-curve network. In: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (2020)
6. NAVER Cloud Platform: Clova ocr product documentation (2026), accessed: 2026-06-08
7. Shi, B., Bai, X., Yao, C.: An end-to-end trainable neural network for image-based sequence recognition and its application to scene text recognition. IEEE Transactions on Pattern Analysis and Machine Intelligence (2017)
8. Shi, B., Yang, M., Wang, X., Lyu, P., Yao, C., Bai, X.: Aster: An attentional scene text recognizer with flexible rectification. IEEE Transactions on Pattern Analysis and Machine Intelligence (2019)
9. Smith, R.: An overview of the tesseract ocr engine. In: International Conference on Document Analysis and Recognition (2007)
10. Wang, Z., Xu, Y., Cui, L., Shang, J., Wei, F.: Layoutreader: Pre-training of text and layout for reading order detection. In: Proceedings of EMNLP (2021)
11. Ye, M., Zhang, J., Zhao, S., Liu, J., Liu, T., Du, B., Tao, D.: Deepsolo: Let transformer decoder with explicit points solo for text spotting. In: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (2023)
12. Zhang, X., Su, Y., Tripathi, S., Tu, Z.: Testr: Text spotting transformers. In: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (2022)
13. Zhou, X., Yao, C., Wen, H., Wang, Y., Zhou, S., He, W., Liang, J.: East: An efficient and accurate scene text detector. In: Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (2017)